网络爬虫作业报告

林涛 3130000064

作业要求

跟踪特定网页，下载该网页中所有链接的指定内容，去除广告等无关内容，组合成单一文件。主要作广度搜索，深度暂为 1。

要求：

1、(基本)不使用第三方工具，如：HttpClient、HtmlParser 等，自己作 String 处理。

2、(提高)可用第三方工具。

3、(可选)自己做一个第三方工具，再爬。

Java 参考：http://www.cjsdn.net/Doc/JDK50/index-files/index-1.html

例：从 http://ds.eywedu.com/jinyong/tlbb/ 下载所有章节，组成完整《天龙八部》.txt。

例：下载某一网页中的所有.jpg 图片，或.mp3、flash 等。

自己作 String 处理

网页特征分析

想要抓取的小说是《书剑恩仇录》和《雪山飞狐》，选取的网页是梦远书城的金庸作品集（http://www.my285.com/wuxia/jinyong/sjecl/ 和 http://www.my285.com/wuxia/jinyong/xsfh/）。分成目录页和内容页分别抓取。

目录页特征

目录中的链接格式如下所示：

这是《雪山飞狐》的——

```
        <tr>
            <td bgcolor="#FFFFFF" align="center"><a href="05.htm">第05页</a></td>
            <td bgcolor="#FFFFFF" align="center"><a href="06.htm">第06页</a></td>
            <td bgcolor="#FFFFFF" align="center"><a href="07.htm">第07页</a></td>
            <td bgcolor="#FFFFFF" align="center"><a href="08.htm">第08页</a></td>
        </tr>
```

这是《书剑恩仇录》的——

```
        <tr>
            <td><a href="014.htm">第三回 避祸英雄悲失路 寻仇好汉误交兵</a> <a href
="015.htm">(2)</a> <a href="016.htm">(3)</a> <a href="017.htm">(4)</a> <a href="018
.htm">(5)</a> <a href="019.htm">(6)</a> <a href="020.htm">(7)</a> <a href="021.htm"
>(8)</a></td>
        </tr>

        <tr>
            <td><a href="022.htm">第四回 置酒弄丸招薄怒 还书贻剑种深情</a> <a href
="023.htm">(2)</a> <a href="024.htm">(3)</a> <a href="025.htm">(4)</a> <a href="026
.htm">(5)</a> <a href="027.htm">(6)</a> <a href="028.htm">(7)</a> <a href="029.htm"
>(8)</a></td>
        </tr>
```

每个链接都是以“<a href="**.htm">”的形式出现的，其中**是一个数字，网页中有一些链接不指向我们需要的内容页，但也有着上面的形式，可以通过判断**是否为数字排除掉。

每一个标签对应章节的标题可以用起始的汉字提取。因为经过观察可以发现每一个标题都开始于“第”和“后”，分别指“第某回（页）”或“后记”。

内容页特征

内容页更为简单，以下是删节的部分内容页：

```
<td colspan="2">
<br>
    清乾隆十八年六月，陕西扶风延绥镇总兵衙门内院，一个十四岁的女孩儿跳跳蹦蹦的走向教书先生书房。上午老师讲完了《资治通鉴》上“赤壁之战”的一段书，随口讲了些诸葛亮、周瑜的故事。午后本来没功课，那女孩儿却兴犹未尽，要老师再讲三国故事。这日炎阳盛暑，四下里静悄悄地，更没一丝凉风。那女孩儿来到书房之外，怕老师午睡未醒，进去不便，于是轻手轻脚绕到窗外，拔下头上金钗，在窗纸上刺了个小孔，凑眼过去张望。只见老师盘膝坐在椅上，脸露微笑，右手向空中微微一扬，轻轻吧的一声，好似甚么东西在板壁上一碰。她向声音来处望去，只见对面板壁上伏着几十只苍蝇，一动不动，她十分奇怪，凝神注视，却见每只苍蝇背上都插着一根细如头发的金针。这针极细，隔了这样远原是难以辨认，只因时交未刻，日光微斜，射进窗户，金针在阳光下生出了反光。<br>
<br>
    陆菲青道：“三更半夜之际，竟劳动三位过访，真是想不到。却不知有何见教？”……陆菲青的招术则似慢实快。一瞬之间两人已拆了十多招。以罗信的武功，怎能与他拆到十招以上？只因陆菲青近年来深自收敛，知道罗信这些人只是贪图功名利禄，天下滔滔，实是杀不胜杀，是以出手之际，颇加容让。<br>
<br>
</td>
```

全部的正文内容都被包括在<td colspan=”2”>和</td>之间。每段文字的结尾有个
，每段文字之间有个
。

抓取方法

使用 Java 自带的 net 包中的网络功能，创建 URL 对象，用 BufferedReader 读取。输出到本地文件夹，用 PrintWriter 连接 FileOutputStream 实现。

所有代码在 Spider 类中，除了 main 函数外，有 parseIndex 和 parsePage 分别处理目录页和内容页。

具体的策略与上面所述相同，需要灵活使用 Java 的 String 类的函数，如 indexOf，substring，charAt，contains 等。

输出时在每章开头加上章节名称和我自己的标识符。在处理每个内容页标签是在 console 输出提示以便于观察。

成果

通过改变 main 函数中的 bookname，分别输出“sjecl.txt”（《书剑恩仇录》）和“xsfh.txt”（《雪山飞狐》）。部分结果如下图所示：

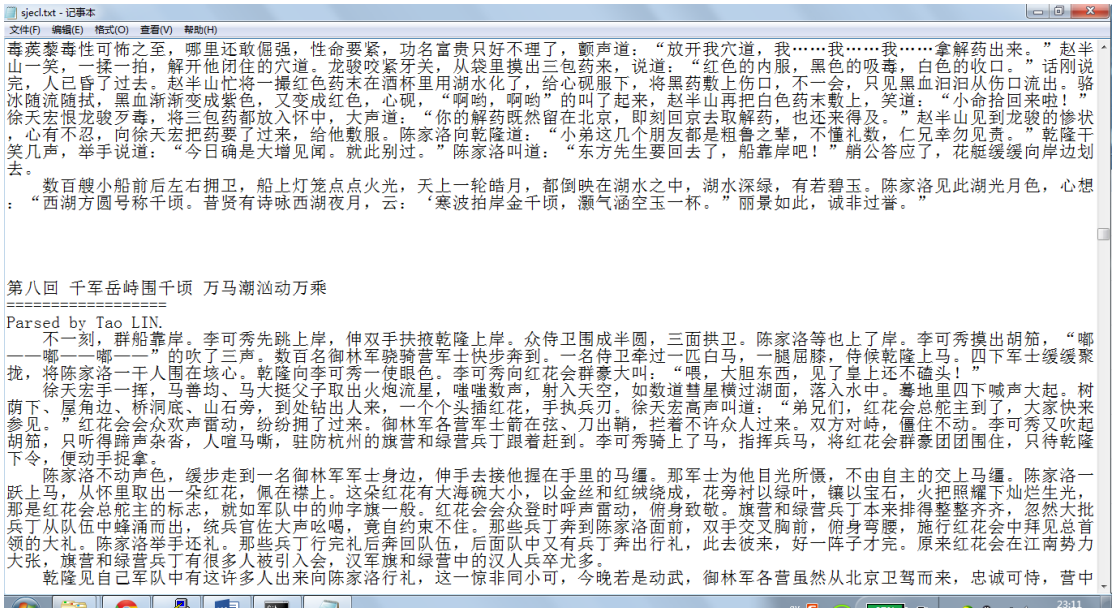

图表 1　《书剑恩仇录》爬虫结果

经肉眼观察，结果完全纯净，没有引入不需要的内容。

Source Code

```
package spider;

import java.net.*;
import java.io.*;

public class Spider {
    public static void main(String argv[]) throws Exception {

        String bookname = "sjecl";    // 书剑恩仇录
//      String bookname = "xsfh";// 雪山飞狐



        PrintWriter outputStream = new PrintWriter(new FileOutputStream(bookname +
 ".txt"));
```

```
        parseIndex(new URL("http://www.my285.com/wuxia/jinyong/"+bookname+"/index.htm"), outputStream);

        outputStream.close();

        System.out.println("Finished.");

    }
    /*
     * Parse the index page of sourceURL and the output is to outputStream
     */
    public static void parseIndex(URL sourceURL, PrintWriter outputStream) throws Exception {
        BufferedReader in = new BufferedReader(new InputStreamReader(sourceURL.openStream()));
        String buf;
        while(!(null==(buf=in.readLine()))){
            int cursor = 0;

            // It is a start if there is a hypertext reference.
            cursor = buf.indexOf("<a href=",cursor);

            // Get the title of the chapter,
            // the titles begin with "第"("第X回") or "后"("后记")
            int startTitle = buf.indexOf("第");
            if(startTitle == -1)
                startTitle = buf.indexOf("后");

            if(startTitle == -1)
                continue;

            int endTitle = buf.indexOf("</a>");
            if(endTitle <= startTitle)
                continue;

            // The title of the chapter
            String title = buf.substring(startTitle, endTitle);

            // Message on console
            System.out.println("Start " + title);

            // My special format for the beginning of each chapter
            outputStream.println("\r\n\r\n\r\n");
            outputStream.println(title);
```

```
            outputStream.println("==================");
            outputStream.println("Parsed by Tao LIN.");

            // Find out each hypertext reference, and parse it.
            while(cursor != -1){
                int left = buf.indexOf('"',cursor) + 1;
                int right = buf.indexOf('"',left);
                String href = buf.substring(left, right);
                // Check the href is what we need
                // (it should begin with a digit)
                if(Character.isDigit(href.charAt(0)) == true){
                    // Get the new URLs and parse each other using parsePage()
                    URL subURL = new URL(sourceURL, href);
                    parsePage(subURL, outputStream);
                }
                cursor = right;
                cursor = buf.indexOf("<a href=",cursor);
            }
        }
        in.close();
    }
    /*
     * Get the context in each page
     */
    public static void parsePage(URL pageURL, PrintWriter outputStream) throws Exc
eption {
//      System.out.println(pageURL.toString());
        BufferedReader in = new BufferedReader(new InputStreamReader(pageURL.openS
tream()));
        String buf;
        boolean start = false;
        while(null != (buf=in.readLine())){
            // The passage in contained between <td colspan="2"> and </td>
            // Each paragraph is surrounded by <br>
            if(start){
                if(buf.contains("</td>"))
                    break;
                int indexEnd = buf.indexOf("<br>");
                if(indexEnd > 0){
                    String para = buf.substring(0,indexEnd);
                    outputStream.println(para);
                }
            }
            else if(buf.contains("<td colspan=\"2\">")){
```

```
                start = true;
            }
        }

        in.close();
    }

    public static void dispAll (URL sourceURL) throws Exception {
        BufferedReader in = new BufferedReader(new InputStreamReader(sourceURL.ope
nStream()));
        String buf;
        while(!(null==(buf=in.readLine()))){
            System.out.println(buf);
        }
    }
}
```

使用 HttpClient

使用经过

HttpClient 提供了访问 Web 和很多函数。按照新版的 API，可以通过 HttpClients.createDefault()创建一个 CloseableHttpClient。然后让这个 Client 去 execute 一个 HttpGet 命令，返回一个 CloseableHttpResponse，取得其 entity。这个 entity 只要 getContent 就是熟悉的 InputStream 了。

运行能抓取整个网页。

后面本来该写个爬虫的，但其余方法与前面没有太大区别，而下面使用 HtmlParser 也不需要用到这个，所以只作为一个独立的实验放在这里了。

Source Code

```
package spider;

import java.io.BufferedReader;
import java.io.IOException;
import java.io.InputStream;
import java.io.InputStreamReader;
```

```
import org.apache.http.HttpEntity;
import org.apache.http.client.ClientProtocolException;
import org.apache.http.client.methods.CloseableHttpResponse;
import org.apache.http.client.methods.HttpGet;
import org.apache.http.impl.client.CloseableHttpClient;
import org.apache.http.impl.client.HttpClients;

public class SpiderClient{
    public static void main(String[] args) throws ClientProtocolException, IOExcep
tion{
        CloseableHttpClient httpclient = HttpClients.createDefault();
        HttpGet httpget = new HttpGet("http://www.my285.com/wuxia/jinyong/xsfh");
        CloseableHttpResponse response = httpclient.execute(httpget);
        try {
            HttpEntity entity = response.getEntity();
            InputStream inputstream = entity.getContent();
        BufferedReader in = new BufferedReader(new InputStreamReader(inputstream))
;
        String buf;
        while(!(null==(buf=in.readLine()))){
            System.out.println(buf);
        }

            httpget.abort();
        } finally {
            response.close();
        }


    }
}
```

使用 HtmlParser

使用经过

给 Parser 传入 url，调用其 parse 函数，获得一个 nodelist。用 Nodelist 的 elements 函数可以得到子节点的迭代器，用迭代器遍历，可以用来迭代直到找到需要的元素。

为了配合 Parser 的特性，我找了目录页的另一个特性——所有需要的链接都是放在一个表格中的。鉴于目录页中并不是只有一个表格，可以用表格的行数来判断是否是我们需要的表格，当行数超过 15 行时，认为是我们需要的含链接的表格。

将表格节点转化为 TableTag 对象，用其自带的 getColumns 和 getRows 得到每一格的内容，得到 LinkTag 对象。用 toPlainTextString 函数得到标题，用 getLink 得到链接。

对于内容页的抓取还是采用原来的方式。

成果

通过改变 main 函数中的 bookname，分别输出“SpiderParser_sjecl.txt”（《书剑恩仇录》）和“SpiderParser_xsfh.txt”（《雪山飞狐》）。部分结果如下图所示：

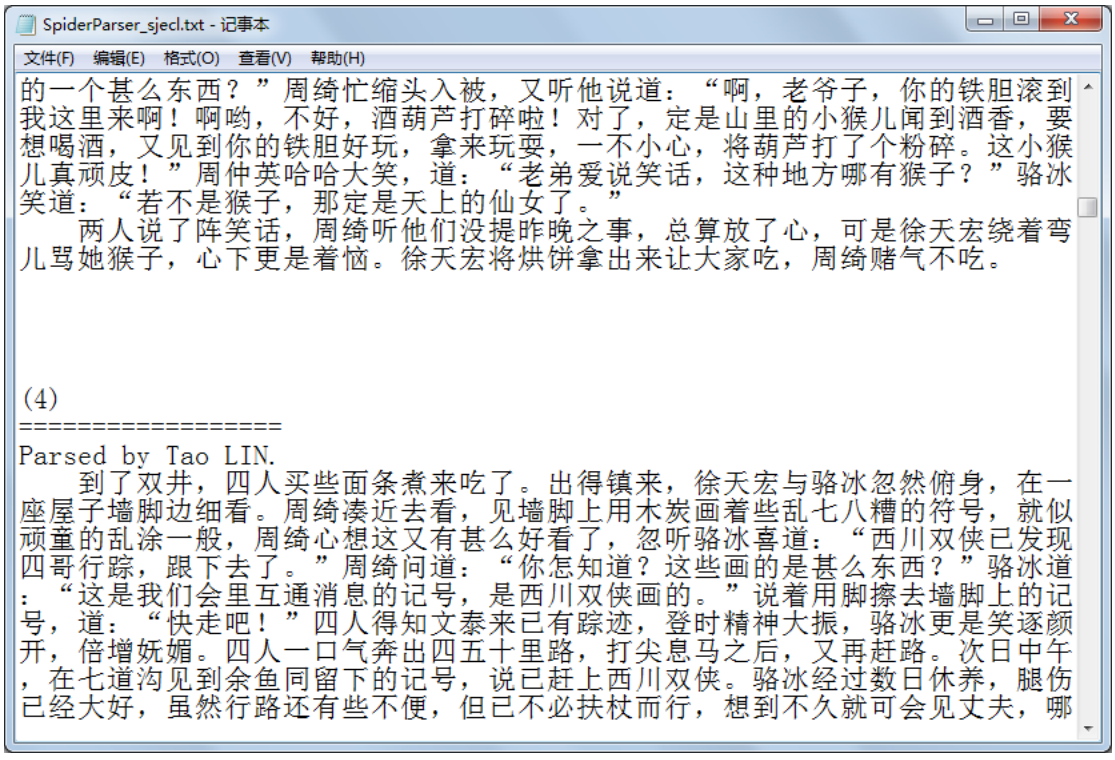

图表 2　《书剑恩仇录》爬虫结果（SpiderParser 版）

Source Code

```
package spider;
```

```
import java.io.BufferedReader;
import java.io.FileNotFoundException;
import java.io.FileOutputStream;
import java.io.InputStreamReader;
import java.io.PrintWriter;
import java.net.MalformedURLException;
import java.net.URL;

import org.htmlparser.Node;
import org.htmlparser.Parser;
import org.htmlparser.tags.LinkTag;
import org.htmlparser.tags.TableColumn;
import org.htmlparser.tags.TableRow;
import org.htmlparser.tags.TableTag;
import org.htmlparser.util.NodeList;
import org.htmlparser.util.ParserException;
import org.htmlparser.util.SimpleNodeIterator;

public class SpiderParser {
    static PrintWriter outputStream;

    /*
     * Parse a book.
     */
    public static void main(String[] argv){
//      String bookname = "sjec1";    // ?????
        String bookname = "xsfh";// ????


        try {
            outputStream = new PrintWriter(new FileOutputStream("SpiderParser_" +
bookname + ".txt"));
        } catch (FileNotFoundException e1) {
            e1.printStackTrace();
        }

        String url = "http://www.my285.com/wuxia/jinyong/"+bookname+"/index.htm";
        // Using htmlParser
        Parser parser = null;
        try {
            parser = new Parser(url);
        } catch (ParserException e) {
            e.printStackTrace();
        }
```

```
        NodeList nodelist = null;
        try {
            nodelist = parser.parse(null);
        } catch (ParserException e) {
            e.printStackTrace();
        }
        // Nodelist of html
        nodelist = nodelist.toNodeArray()[0].getChildren();

        findTable(nodelist);

        outputStream.close();
    }
    /*
     * Find out all tables in the node list.
     */
    public static void findTable(NodeList nodelist){
        if(null == nodelist){
            return;
        }
        SimpleNodeIterator iterator = nodelist.elements();
        while(iterator.hasMoreNodes()){
            Node node = iterator.nextNode();
            if(node instanceof TableTag){
                parseTable(node);
            }
            // Do it recursively to its children,
            // even it is a table.
            NodeList childNodeList = node.getChildren();
            findTable(childNodeList);
        }
    }
    /*
     * Select the table we need and parse it.
     */
    public static void parseTable(Node node){
        TableTag table = (TableTag) node;
        // The table we need is larger than 15.
        if(table.getChildren().size() > 15){
            TableRow[] rows = table.getRows();
            for(int i=0;i<rows.length;i++){
                TableRow row = rows[i];
                TableColumn[] columns = row.getColumns();
                for(int j=0;j<columns.length;j++){
```

```
                    TableColumn column = columns[j];
                    Node[] links = column.getChildrenAsNodeArray();
                    for(int k=0;k<links.length;k++){
                        if(links[k] instanceof LinkTag){
                            LinkTag link = (LinkTag) links[k];
                            // The title is the context of the link.
                            String title = link.toPlainTextString();
                            // Message on console
                            System.out.println("Start " + title);

                            // My special format for the beginning of each chapte
r
                            outputStream.println("\r\n\r\n\r\n");
                            outputStream.println(title);
                            outputStream.println("==================");
                            outputStream.println("Parsed by Tao LIN.");

                            try {
                                parsePage(new URL(link.getLink()));
                            } catch (MalformedURLException e) {
                                e.printStackTrace();
                            } catch (Exception e) {
                                e.printStackTrace();
                            }
                        }
                    }
                }
            }
        }
    }
    /*
     * Parse each sub-page in the traditional way,
     * as it is much easier.
     */
    public static void parsePage(URL pageURL) throws Exception{
        BufferedReader in = new BufferedReader(new InputStreamReader(pageURL.openS
tream()));
        String buf;
        boolean start = false;
        while(null != (buf=in.readLine())){
            // The passage in contained between <td colspan="2"> and </td>
            // Each paragraph is surrounded by <br>
            if(start){
                if(buf.contains("</td>"))
```

```
                    break;
                int indexEnd = buf.indexOf("<br>");
                if(indexEnd > 0){
                    String para = buf.substring(0,indexEnd);
                    outputStream.println(para);
                }
            }
            else if(buf.contains("<td colspan=\"2\">")){
                start = true;
            }
        }

        in.close();
    }
}
```

参考资料

JavaTM Platform Standard Edition 6 API 规范 http://www.cjsdn.net/Doc/JDK60/

HttpClient 使用详解 http://blog.csdn.net/wangpeng047/article/details/19624529

使用 HttpClient 和 HtmlParser 实现简易爬虫

https://www.ibm.com/developerworks/cn/opensource/os-cn-crawler/

httpclient 的一些学习心得 http://wallimn.iteye.com/blog/540566

HttpClient Tutorial http://hc.apache.org/httpcomponents-client-ga/tutorial/pdf/httpclient-tutorial.pdf